

Sistema de Detección de Sentimiento en Reseñas de Usuarios (DSR-AI)

Análisis exploratorio de datos

Universitat Politècnica de València

Grado en Inteligencia Artificial

Proyecto I. Introducción a la IA

Adrián A. Acosta Villegas

Sergio Garfella Pérez

Ainara Sanfélix Ruiz

Jairo E. Urdaneta Colmenares

1. Accesibilidad y Preparación de los Datos

Descripción de los Datasets

Para el desarrollo del sistema de detección de sentimiento usamos tres conjuntos de datos de referencia en el ámbito del análisis de sentimiento de reseñas cinematográficas. Cada uno tiene características distintas en cuanto a volumen, estructura y nivel de detalle, lo que enriquece la diversidad del corpus de entrenamiento.

Dataset	Fuente	Formato	Clasificación	Registros etiquetados
acllmbd	Stanford (Maas et al., 2011)	Archivos TXT	Binaria (pos/neg)	50.000
review_polarity	Cornell (Pang & Lee, 2004)	Archivos TXT	Binaria (pos/neg)	2.000
standfordSTT	Stanford (Socher et al., 2013)	Archivos TSV	5 clases) → Binaria	11.286

El dataset **acllmbd** es el más extenso, con 50.000 reseñas etiquetadas (25.000 positivas y 25.000 negativas) divididas a su vez en conjuntos de entrenamiento (25.000) y test (25.000). Cada archivo lleva en su nombre una puntuación original del 1 al 10. El *dataset* **review_polarity** contiene 2.000 reseñas (1.000 positivas y 1.000 negativas) organizadas en 10 particiones de validación cruzada (cv000 a cv009). El *dataset* **standfordSTT** tiene 11.855 frases con puntuaciones de sentimiento continuas en el rango [0; 0,2] (muy negativo) a [0,8; 1,0] (muy positivo), con una estructura de árbol sintáctico que permite análisis a nivel sub-frase.

Unificación de los *datasets*

Para poder trabajar con los tres orígenes de forma conjunta, hemos realizado el siguiente proceso de unificación.

1. Carga e inspección: Cargamos cada *dataset* en su formato particular.

2. Conversión a binario (STT): Al ser el único *dataset* con sentimiento continuo, hemos aplicado un umbral para convertir la puntuación [0,0; 1,0] a etiqueta binaria. Hemos establecido: puntuación $\geq 0,6 \rightarrow$ **positivo**, puntuación $\leq 0,4 \rightarrow$ **negativo**. Las frases con puntuación en el rango (0,4; 0,6) las hemos descartado por ser de sentimiento neutral o ambiguo.

3. DataFrame unificado: Hemos creado un DataFrame común con las columnas: texto (contenido de la reseña), sentimiento (pos/neg), dataset (origen) y split (train/test/cv/dev).

4. DataFrame unificado con análisis: Para facilitar el análisis añadiremos al DataFrame anterior variables derivadas del texto: longitud, vocabulario y número de caracteres.


Resultados de la preparación

Métrica	Valor
Registros originales (3 datasets)	72.601
Registros etiquetados (pos/neg)	70.327
Reseñas vacías eliminadas	0
Duplicados eliminados	600
Stanford neutrales descartados ($0,4 < \text{score} < 0,6$)	2.274
Dataset unificado	69.727

2. Análisis Univariante

Distribución de Sentimiento

La variable objetivo del problema es el sentimiento de la reseña, codificado como positivo o negativo. A nivel global, el conjunto tiene una distribución prácticamente equilibrada, con un 50,4% de reseñas positivas (35.127) frente a un 49,6% de negativas (34.600). Este equilibrio es gracias al diseño de los datasets originales, que fueron contruidos con representación equitativa de ambas clases.




Visualizando los gráficos de distribución de cada *dataset*, llegamos a la conclusión de que el más equilibrado es **review_polarity**, con una distribución totalmente equilibrada de 50% reseñas positivas frente a un 50% de reseñas negativas. Seguido de **aclImdb** con un 50,2% de reseñas positivas y un 49,8% de negativas. Por último **stanfordSST** que cuenta con un 51,8% de positivas y 48,2% de negativas.

Distribución de Longitud de Reseñas

Hemos analizado tres medidas de longitud: Número de palabras, número de caracteres y número de frases.


Distribución de palabras



	acllmbd	review polarity	stanfordSTT	Unificado
Media	231,4	21,0	19,3	170,4
Std	171,5	9,4	9,2	173,5
Mínimo	4,0	1,0	2,0	1,0
P25	126,0	14,0	12,0	31,0
Mediana	173,0	20,0	19,0	133,0
P75	281,0	27,0	25,0	223,0
P95	591,0	38,0	36,0	523,0
Máximo	2470,0	59,0	56,0	2470,0

La distribución de palabras muestra grandes diferencias y asimetrías: **acllmbd** tiene una gran variedad y extensión (mediana de 173 palabras), mientras que **standfordSTT** y **review_polarity** se concentran en el extremo inferior (mediana de 20 palabras). Esto resulta en un Dataset Unificado con alta dispersión, donde obtenemos una mediana de 133 palabras.


Distribución de caracteres



	aclImdb	review polarity	stanfordSTT	Unificado
Media	1310,6	114,3	103,8	963,5
Std	990,8	51,2	50,8	997,6
Mínimo	32,0	4,0	5,0	4,0
P25	699,0	76,0	64,0	168,0
Mediana	971,0	111,0	100,0	736,0
P75	1592,0	149,0	138,0	1260,0
P95	3394,0	205,0	194,0	2997,7
Máximo	13704,0	267,0	283,0	13704,0

En cuanto a los caracteres, hay una correlación directa con el número de palabras. **aclImdb** sigue como el único dataset con textos largos, mientras que los otros dos conjuntos son muy compactos y uniformes, sin superar nunca los 300 caracteres. Esto nos proporciona un dataset unificado más variado.

Distribución de frases



	aclImdb	review polarity	stanfordSTT	Unificado
Media	13,3	1,2	1,1	9,8
Std	9,3	0,5	0,3	9,6
Mínimo	1,0	1,0	1,0	1,0
P25	7,0	1,0	1,0	1,0
Mediana	11,0	1,0	1,0	8,0
P75	16,0	1,0	1,0	13,0
P95	32,0	2,0	2,0	28,0
Máximo	150,0	7,0	4,0	150,0

La diferencia estructural clave es la longitud: aclImdb consta de textos de párrafos (mediana de 11 frases), mientras que review_polarity y stanfordSentimentTreebank son colecciones de frases cortas (mediana de 1 frase). Esto hace que el *dataset* Unificado sea un híbrido con unidades simples y estructuras complejas de hasta 150 frases.

Conclusión de la longitud de reseñas

Concluimos que hay dos tipos de *datasets* diferentes en cuanto a longitud: acllmdb tiene textos largos y los otros dos son breves. Este desequilibrio en la longitud de las entradas (de 2 palabras a más de 2.000) puede ser un reto para el modelo de Machine Learning. Es posible que sea un punto crítico.

Análisis de Vocabulario y Ley de Zipf

Análisis de Vocabulario

Analizaremos el vocabulario para determinar su distribución y riqueza léxica, entendida como la variedad y complejidad del lenguaje que utiliza un autor o hablante. También identificaremos el "ruido" en cada *dataset* que no aporte valor a la predicción.

Estudiamos las métricas fundamentales de riqueza léxica y volumen de datos.

 **Tokens:** El número total de palabras en un texto.

Types: El número de palabras únicas.

TTR (Type-Token Ratio): Relación entre el número de palabras únicas y el total de palabras de un texto. Se utiliza para medir la riqueza léxica. El TTR puede ser alto o bajo: un valor alto indica una mayor variedad de vocabulario (con poca repetición de palabras), mientras que un valor bajo refleja un uso más limitado del léxico y una mayor repetición.

Hapax Legomena: Palabras que aparecen una sola vez en la totalidad del conjunto de datos.

	stanfordSST	review polarity	acllmdb	Unificado
Total Tokens	183.763	223.689	11.470.804	11.878.256
Type (Únicas)	17.412	21.381	390.931	394.370
TTR (Ratio Type/Token)	0,0948	0,0956	0,0341	0,0332
Hapax Legomena (Freq=1)	8.645 (49,6%)	11.013 (51,5%)	239.058 (61,2%)	239.624 (60,8%)

Concluimos que el conjunto de datos **acllmbd** es tan grande que aporta más del 96% de las palabras del texto unificado. Por lo tanto, cualquier decisión o tendencia del modelo estará fuertemente sesgada por este dataset.

Al analizar textos más amplios, el ingreso de palabras nuevas disminuye y se repiten las ya existentes (el ratio TTR cae de ~0,09 a 0,03). Además, el 61% de las palabras del vocabulario total aparecen una sola vez en todos los textos. Para un modelo predictivo, esto representa ruido e ineficiencia, no información útil.


Las palabras más repetidas en el tope de la lista son exclusivamente artículos, preposiciones y signos de puntuación. Estas dominan el volumen del texto, pero no aportan ninguna pista sobre si la reseña es positiva o negativa.

Comprobación de la Ley de Zipf

Estudiaremos cuantas veces se repiten las palabras en los *datasets* y le asignaremos un valor en un rango, en función de las veces que ha aparecido. (lo visualizamos en un gráfico).

Calculamos la pendiente e intercepto para evaluar matemáticamente si las distribuciones de frecuencias de los *datasets* siguen la proporción inversa postulada por Zipf (cuya pendiente ideal en un gráfico log-log es de aproximadamente un: -1.0).

	review polarity	stanford Sentiment Treebank	acllmbd	Unificado
Pendiente de Zipf	-1,089	-1,094	-1,196	-1,204
Intercepto	4,585	4,520	6,480	6,529



Todos los conjuntos de datos presentan una estructura propia del lenguaje natural, pero revelan una distribución muy extrema: al tener pendientes ligeramente más pronunciadas que el ideal teórico, demuestran que un pequeño grupo de palabras vacías (artículos, preposiciones, conjunciones, signos de puntuación) acapara la inmensa mayoría del texto, mientras que se forma una gigantesca "larga cola" compuesta por miles de términos que aparecen una sola vez (*hapax legomena*). Debemos recortar los dos extremos del vocabulario para no saturar al modelo predictivo con ruido.

Decisiones a realizar

Eliminación de palabras vacías y puntuación: Quitaremos las palabras que se repiten frecuentemente (artículos, preposiciones) y signos ortográficos que saturan el texto sin aportar

- información sobre el sentimiento de las opiniones.

Poda del vocabulario (*Trimming*): Eliminaremos la extensa larga cola de palabras raras para


- descartar el ruido, ahorrar memoria y evitar que el modelo sufra de sobreajuste (*overfitting*).

Normalización del texto: Convertiremos todo el texto a minúsculas y transformaremos las palabras a su forma base para unificar términos gramaticalmente similares, reduciendo así el tamaño del diccionario y concentrando la señal predictiva.

3. Análisis Multivariante

Longitud vs Sentimiento

Correlación entre las variables











Los resultados indican que hay alta multicolinealidad entre las tres variables. Por tanto, realizaremos pruebas únicamente con la variable número de palabras que nos servirá de representación de la longitud.

Vamos a investigar si existe una relación entre la longitud de las reseñas y el sentimiento expresado.

Comparamos las distribuciones de longitud (número de palabras) entre reseñas positivas y negativas en cada *dataset*.

Comparación de distribuciones



Test de Mann-Whitney U

Como no hay normalidad, tendremos que realizar el test no paramétrico Mann-Whitney U para comprobar si hay diferencias significativas.

	acllmdb	review_polarity	stanfordSST	Unificado
Media Pos.	233,1	21,13	19,46	171
Media Neg.	229,6	20,96	19,14	169,6
Mediana Pos.	172,0	20	19	131
Mediana Neg.	174.0	21	18	135
U de Mann-Whitney	31.0652.184	14.010.333	11.140.190	613.882.594
P-valor	0,035	0,4906	0,2128	0,01993
¿Significativo?	No	No	No	No

Con un 99% de confianza el test nos asegura que no hay diferencias estadísticamente significativas en el sentimiento según la longitud de las reseñas. Pese a eso destacamos que en el dataset unificado es donde encontramos mayores diferencias (con un p-valor de 0,019).

Concluimos que la longitud por sí sola no es buen predictor del sentimiento.

Vocabulario Significativo

Vamos a estudiar qué palabras son características de cada clase.


Frecuencias absolutas

Para ello, dividimos nuestros datos según el sentimiento y calculamos la frecuencia absoluta de cada término y su clase (identificando también si está en las dos clases).


Total de palabras positivas	6.008.760
Total de palabras negativas	5.869.796
Vocabulario exclusivo positivo	147.111
Vocabulario exclusivo negativo	140.793
Vocabulario compartido	106.466

Log-Odds Ratio

Utilizamos los Log-Odds Ratio (LOR) para medir la fuerza de asociación de cada palabra con su sentimiento (calculamos la proporción de uso de la palabra en cada sentimiento). Además, aplicamos el suavizado de *Laplace* (sumar 1 a todas las frecuencias) para evitar divisiones entre cero. De tal manera que obtenemos en nuestro **Dataset Unificado**.



También comparamos cada *dataset* individual:



Prueba de relevancia

Para comprobar si cada palabra es significativamente importante en el sentimiento de la reseña aplicamos el Test *Chi-cuadrado*. Establecemos un nivel de confianza del 95%.

Para comprobar el tamaño del efecto de cada palabra sobre el el sentimiento final utilizamos la V de Cramér. Esta mide lo fuerte que es la asociación. Establecemos los siguientes umbrales:

- $V < 0.01 \rightarrow$ Efecto nulo
- $V < 0.03 \rightarrow$ Efecto pequeño
- $V < 0.05 \rightarrow$ Efecto medio
- $V \geq 0.05 \rightarrow$ Efecto grande


Palabra	χ^2	p-valor	V de Cramér	Asociación
wonderfully	334.0	1.27e-74	0.0053	Nulo
delightful	242.1	1.40e-54	0.0045	Nulo
captures	251.5	1.25e-56	0.0046	Nulo
beautifully	436.5	6.40e-97	0.0061	Nulo
underrated	191.8	1.30e-43	0.0040	Nulo
extraordinary	168.5	1.56e-38	0.0038	Nulo
excellent.	171.9	2.88e-39	0.0038	Nulo
superb	405.5	3.55e-90	0.0058	Nulo
brilliantly	179.2	7.19e-41	0.0039	Nulo
friendship	185.1	3.68e-42	0.0039	Nulo
touching	307.9	6.28e-69	0.0051	Nulo
finest	210.8	9.09e-48	0.0042	Nulo
gem	197.1	9.06e-45	0.0041	Nulo
outstanding	253.7	4.02e-57	0.0046	Nulo
wonderful	1113.3	4.15e-244	0.0097	Nulo
portrait	138.6	5.50e-32	0.0034	Nulo

terrific	284.6	7.51e-64	0.0049	Nulo
magnificent	166.2	5.02e-38	0.0037	Nulo
excellent	1213.8	6.18e-266	0.0101	Pequeño
remarkable	202.5	5.95e-46	0.0041	Nulo
instead.	156.9	5.31e-36	0.0036	Nulo
terrible	1011.0	7.25e-222	0.0092	Nulo
stupid	1137.1	2.84e-249	0.0098	Nulo
crappy	232.4	1.83e-52	0.0044	Nulo
horrible	832.4	4.81e-183	0.0084	Nulo
bad,	769.9	1.91e-169	0.0081	Nulo
pathetic	320.9	9.30e-72	0.0052	Nulo
badly	531.8	1.17e-117	0.0067	Nulo
ridiculous.	168.1	1.97e-38	0.0038	Nulo
worse.	213.2	2.75e-48	0.0042	Nulo
worse	939.9	2.05e-206	0.0089	Nulo
bad.	903.4	1.80e-198	0.0087	Nulo
awful	1117.7	4.65e-245	0.0097	Nulo
wasted	592.7	6.62e-131	0.0071	Nulo
lame	603.1	3.54e-133	0.0071	Nulo
pointless	449.0	1.20e-99	0.0061	Nulo
poorly	885.1	1.68e-194	0.0086	Nulo
redeeming	428.4	3.59e-95	0.0060	Nulo
worst	3539.5	0.00e+00	0.0173	Pequeño
waste	2091.2	0.00e+00	0.0133	Pequeño

A pesar de tener muchas palabras que son significativas en el sentimiento de la reseña, destacamos que su impacto es nulo en la mayoría de casos, o pequeño (en *worst*, *waste* y *excellent*).

Análisis de pares y tríos de palabras

Estudiamos los pares de palabras y tríos de palabras significativas más frecuentes en cada clase para identificar patrones característicos del sentimiento (eliminando palabras vacías y signos de puntuación).



Cabe recalcar que a veces los usuarios dicen su puntuación sobre 10 y nos es útil para clasificar la reseña. Además de que también usan adjetivos superlativos para expresar su opinión.


4. Evaluación de Supuestos

Normalidad de las Variables Numéricas

Comprobamos la normalidad en las variables numéricas mediante el test de Shapiro-Wilk. También visualizamos los gráficos Q-Q.

Dataset	Variable	W (Shapiro-Wilk)	p-valor	¿Normal?
acllmdb	N. Caracteres	0.77716	2.2e-16	No
acllmdb	Longitud Reseñas	0.78816	2.2e-16	No
acllmdb	Vocabulario	0.83576	2.2e-16	No
review_polarity	N. Caracteres	0.98577	2.2e-16	No
review_polarity	Longitud Reseñas	0.98532	2.2e-16	No
review_polarity	Vocabulario	0.99023	2.2e-16	No
stanfordSST	N. Caracteres	0.982	2.2e-16	No
stanfordSST	Longitud Reseñas	0.97847	2.2e-16	No
stanfordSST	Vocabulario	0.98474	2.2e-16	No

Q-Q plot Datasets



Ninguna de las variables numéricas sigue una distribución normal en ninguno de los tres datasets. Los p-valores son extremadamente pequeños (mucho menores que 0.01), lo que permite rechazar la hipótesis nula de normalidad. Los gráficos Q-Q confirman visualmente las desviaciones, especialmente en las colas de la distribución.

- El algoritmo k -NN no asume normalidad de los datos, por lo que este resultado no es problemático. Sin embargo, la ausencia de normalidad refuerza la necesidad de usar tests no paramétricos como *Mann-Whitney U* (ya usados). Además, la fuerte asimetría nos sugiere que debemos normalizar las variables antes de aplicar *Doc2Vec* y k -NN

Homogeneidad de Varianzas

Varianzas de variables del *dataset*

Variable	F-value (Levene)	p-valor	¿Homogéneas?
N. Caracteres	31.177	2.365e-08	No
Longitud Reseñas	20.671	5.464e-16	No
Vocabulario	13.547	0.0002329	No

La varianza de las variables es heterogenea.

 Deberemos normalizar las características antes del entrenamiento del modelo. Usaremos *Doc2Vec* para proyectar los textos en un mismo espacio vectorial, independientemente de su longitud u origen.

5. Detección de Valores Atípicos (Outliers)

Detección mediante IQR y Z-Score

Utilizamos el rango intercuartílico y el Z-Score para detectar los outliers de nuestro *dataset* unificado.

Variables	Q1	Q3	IQR	Límite inferior	Límite superior	Outliers IQR	Outliers Z>3
Palabras	31	223	192	-257*	511	3.691 (5,29%)	1.546 (2,22%)
Palabras únicas	27	149	122	-156*	332	2.521 (3,62%)	1.280 (1,84%)
Caracteres	168	1.260	1.092	-1.470*	2.898	3.812 (5,47%)	1.559 (2,24%)

Alrededor del 5% (según IQR) o el 2% (según Z-Score) son textos atípicos. No es una cantidad masiva que invalide el dataset, pero lo ajustaremos.

Límites negativos

Los límites inferiores negativos confirman que las anomalías son textos extremadamente largos o verbosos, ya que son los que desvirtuan el límite inferior y media.

Elegimos el método IQR en lugar del Z-score porque la distribución altamente asimétrica de los textos invalida a este último (como vemos en los valores negativos). Genera límites estadísticos irreales al verse sesgado por reseñas extremadamente largas que inflan su media.

Reseñas con Caracteres Anómalos

Analizamos el ratio de caracteres no textuales (espacios, puntuación, números, símbolos HTML) respecto al total de caracteres de cada reseña.

Métrica	Valor
Ratio medio	0,215 (21,5%)
Ratio mediano	0,214
Reseñas con ratio > 30%	506 (0,73%)
Reseñas con ratio > 50%	3 (0%)
Ratio máximo	0,873

El *dataset* tiene una excelente estructura, con un ratio medio normal del 21,5% de caracteres no textuales (normales de la redacción natural). La limpieza general es notable, apenas el 0,73% de las reseñas excede el umbral crítico del 30% de anomalías. Sin embargo, el valor máximo de 0.873 nos advierte que hay casos aislados con ruido extremo. Eliminaremos estos pocos registros para evitar que distorsionen las métricas geométricas del algoritmo K-NN.

Reseñas Extremas

Tipo	Cantidad	Porcentaje	Distribución sentimiento
Muy cortas (< 5 palabras)	417	0.6%	189 pos / 228 neg
Muy largas (> percentil 99)	695	1%	379 pos / 316 neg

Las reseñas extremas constituyen una fracción marginal del dataset (apenas un 1,6% en conjunto), lo que muestra una gran normalidad en la longitud general de los textos. Las reseñas muy cortas (0,6%) muestran una leve tendencia hacia la negatividad. Por el contrario, el 1% de reseñas excepcionalmente largas se inclina hacia la positividad. De cara al modelo KNN, la estrategia óptima es eliminar los textos excesivamente cortos por su falta de contexto, y truncar (winsorizar) los muy largos para estabilizar el cálculo geométrico de distancias.

Decisión sobre el tratamiento de outliers

- **Eliminar registros sin contexto o con ruido:** Descartaremos las reseñas excesivamente cortas (menos de 5 palabras) por carecer de valor semántico suficiente para el análisis de sentimiento. Asimismo, eliminaremos los casos aislados con un ratio de caracteres anómalos superior al 30% para evitar distorsiones geométricas en el modelo.
- **Truncar reseñas extremadamente largas (Winsorización):** Para estabilizar el cálculo de distancias de K-NN sin perder información valiosa, pondremos un límite a los valores de los textos que superen el percentil 99.
- **Priorizar IQR sobre Z-Score:** Utilizaremos exclusivamente el Rango Intercuartílico (IQR) para definir los límites de truncamiento, ya que la distribución altamente asimétrica de los textos sesga la media y genera límites estadísticos irreales e inválidos si se emplea el Z-Score.

Valores ausentes (*missing*)

- ✓ Nuestro dataset, por su origen académico y didáctico no tiene valores ausentes. Será un problema que no tendremos que tratar.



6. Conclusiones del análisis exploratorio de datos

En nuestro análisis exploratorio de los tres *datasets* hemos concluido:

1. **Buen equilibrio de clases:** Las clases positiva y negativa están equilibradas, lo que elimina la necesidad de técnicas de sobremuestreo o submuestreo y facilita el entrenamiento del clasificador k-NN.
2. **Ausencia de normalidad y varianza heterogénea:** Los test estadísticos nos confirman que ninguna variable numérica sigue una distribución normal. Además, hemos comprobado la heterogeneidad de la varianza. Aunque K-NN no exige normalidad, esta fuerte asimetría y dispersión hacen obligatoria la normalización de las variables numéricas antes del entrenamiento.
3. **Vocabulario diferencial claro:** Existe una separación léxica bien definida entre clases (palabras como *great, excellent, love, worst, terrible, boring*).
4. **Tratamiento de Outliers:** Ejecutaremos una limpieza estructural eliminando registros sin contexto o con un ruido extremo. Para proteger el cálculo de distancias del algoritmo K-NN, truncaremos las reseñas excesivamente largas utilizando los límites del Rango Intercuartílico, ya que la asimetría de los datos invalida el uso del Z-Score.
5. **Necesidad de limpieza semántica:** Es necesario que apliquemos técnicas de procesamiento de lenguaje natural. Esto incluye la eliminación de palabras vacías y puntuación, y la normalización del texto (minúsculas) para unificar términos, reducir el diccionario y potenciar la señal predictiva.
6. **Uso de Doc2Vec:** Para reducir las diferencias superficiales de longitud y origen, y proyectar los textos en un espacio vectorial homogéneo, se utilizará *Doc2Vec* en conjunto con K-NN. Esto permitirá capturar el contenido semántico esencial para la clasificación.